

proyecto aprendizaje de maquinas

Johan Stiveen Dueñas Lopez
Juan Sebastian Herrera Suarez
Jose david Tarazona Diaz



Dataset



El dataset que utilizamos contiene información detallada sobre **1,028 Pokémon** de distintas generaciones. Incluye estadísticas de combate como HP, Ataque, Defensa, Velocidad, así como características como el tipo, generación y si el Pokémon es legendario o no

Fuente: Kaggle — Pokémon Dataset

Features usadas: HP, Attack, Defense, Sp.Atk, Sp.Def, Speed, Generation, Type_1, Type_2

Variable objetivo: Is_legendary(0 = No legendario, 1 = Legendario)

Preprocesamiento: eliminación de nulos selectiva, codificación de variables categóricas con LabelEncoder y normalización con StandardScaler para Deep Learning y PCA

Metodos ML

A lo largo del proyecto realizado en el semestre fuimos utilizando diferentes metodos en especial durante el segundo corte utilizamos 3 metodos ml que nos brindaron resultados e informacion del dataset que son:

Modelo	parámetro	Valores
Decision Tree	max_depth	3, 5, 8, None
Random Forest	n_estimators	50, 100, 200
SVM	kernel	linear, poly, rbf



Deep Learning



cuando empezamos a realizar la etapa de deep learning usamos 3 arquitecturas con epochs de 10, 50 y 100. por lo tanto, la activacion se uso ReLU en capas ocultas con el optimizador adam ademas de normalizar los datos con standardScaler

Modelo	capas ocultas
Modelo 1	64 → 128 → 128
Modelo 2	64 → 64 → 128 → 128 → 256 → 256
Modelo 3	10 capas de 128 neuronas



Aprendizaje No Supervisado



Durante esta etapa del proyecto utilizamos metodos de aprendizaje no superviasado al dataset asi como la forma para reducir dimensionalidad con el PCA que nos redujo las 9 features a 2 componentes principales u nos dejo una varianza de casi 44%. Los analisis fueron:

Método	Descripción	Resultado
KMeans	n_clusters = 2	2 grupos con centroides definidos
DBSCAN	eps = 0.5	1 cluster + 7 puntos de ruido



Conclusiones

- La limpieza selectiva fue clave para conservar suficientes datos
- El Random Forest demostró mayor estabilidad gracias al ensamble de árboles
- El SVM con kernel rbf manejó bien la no-linealidad del problema
- El Deep Learning con más epochs converge mejor pero puede presentar overfitting en datasets pequeños
- PCA permitió visualizar los datos en 2D conservando el 43.89% de la varianza
- KMeans separó mejor los grupos que DBSCAN para este dataset desbalanceado
- Los Pokémon legendarios son difíciles de clusterizar automáticamente por su baja representación



muchas gracias